

推理过程



原始图像 x


攻击者拟定类别

y

$\mathcal{L}_{cls}$

y'

ϵ



x'